

Enunciado do Projeto Integrador

Estratégia End-to-End

1. Enquadramento e Objetivo

O Projeto Integrador constitui o elemento central de avaliação desta UC. O desafio para os grupos de alunos consiste em conceber uma **estratégia completa de *Enterprise Data Analytics* para uma organização real** (ou fictícia plausível), demonstrando como os dados são transformados em valor mensurável para suportar decisões estratégicas e operacionais.

Os alunos deverão evoluir do conceito de *Business Intelligence (Reporting)* para *Business Analytics* (Decisão), integrando tecnologia, processos e pessoas.

Cada grupo deverá definir explicitamente um problema de negócio central (ex: *churn*, risco de crédito, otimização de stock, fraude, etc.), que servirá de fio condutor para todos os blocos do projeto.

Questão orientadora

Como pode a organização utilizar dados para melhorar uma decisão crítica do negócio?

O projeto deve obrigatoriamente utilizar um *dataset* real ou realista, com dimensão suficiente para suportar análise exploratória e modelação preditiva.

Cada grupo deverá justificar pelo menos uma decisão técnica relevante com base em *trade-offs* (ex: ETL vs ELT, modelo escolhido, arquitetura).

O projeto deve incluir **evidência prática de execução analítica**, nomeadamente exploração de dados, construção de métricas/KPIs e pelo menos um protótipo funcional de modelo ou mecanismo de apoio à decisão.

2. Estrutura do Projeto

O relatório final deve integrar obrigatoriamente os seguintes blocos, correspondentes aos módulos **A a H** do programa:

Bloco I: Estratégia, Valor e Monetização (Módulo A)

- 🚦 **Diagnóstico de Maturidade:** Avaliar o estado atual da organização em termos analíticos.
- 🚦 **Monetização:** Identificar oportunidades de monetização direta ou indireta dos dados para gerar impacto financeiro mensurável (ex: redução de custos, aumento de receita ou eficiência).

Bloco II: Arquitetura Técnica e Pipeline de Dados (Módulos B, D e F)

- ✚ **Arquitetura de Referência:** Desenhar as camadas técnicas (fontes, ingestão, armazenamento, análise e consumo).
- ✚ **Pipeline (ETL/ELT):** Definir a estratégia de aquisição, limpeza e integração de dados, justificando a escolha entre modelos ETL ou ELT.

Bloco III: Modelação e Armazenamento (Módulo C)

- ✚ **Modelo Dimensional:** Desenhar um esquema em estrela (*Star Schema*) ou floco de neve (*Snowflake*) para um processo de negócio específico.
- ✚ **DW/Lake/Lakehouse:** Justificar a escolha da infraestrutura de armazenamento analítico com base no volume e variedade de dados.

Bloco IV: Data Governance e Compliance (Módulo E)

- ✚ **Políticas de Dados:** Definir regras de qualidade, gestão de metadados e Master Data Management (MDM).
- ✚ **Privacidade e Segurança:** Elaborar as políticas de conformidade com o RGPD e proteção de dados sensíveis.

Bloco V: Domínios Analíticos e Aplicação Prática (Módulo G)

O grupo deve demonstrar a aplicabilidade da solução através de casos reais que cubram os quatro espectros da analítica:

1. **Descritiva (obrigatório):** O que aconteceu? (ex: *Dashboards* de performance).
2. **Diagnóstica (facultativo¹):** Porque aconteceu? (ex: Análise de *drivers* de abandono/*churn*).
3. **Preditiva (obrigatório):** O que vai acontecer? (ex: Modelos de previsão de procura ou risco de crédito).
4. **Prescritiva (facultativo¹):** O que devemos fazer? (ex: Sistemas de recomendação ou otimização de preços/rotas).

Os modelos desenvolvidos deverão basear-se nos conceitos explorados em aula (ex: classificação com regressão logística), podendo ser estendidos com outras abordagens.

Bloco VI: Gestão de Projeto e Roadmap (Módulo H)

- 🚦 **Roadmap de Implementação:** Definir as fases do projeto, recursos necessários e KPIs de sucesso.
- 🚦 **Gestão de Risco:** Identificar riscos técnicos, organizacionais e éticos, propondo estratégias de mitigação.

¹ Valoriza-se a resposta facultativa.

3. Metodologia e Ferramentas

O trabalho deve ter um perfil marcadamente aplicado, focando-se em decisões justificadas e *trade-offs* (custo vs. risco vs. valor). Devem ser utilizadas, conforme necessário, as seguintes ferramentas:

- 🔗 **SQL:** Para modelação e métricas.
- 🔗 **Python:** Para prototipagem de modelos preditivos e transformações.
- 🔗 **Power BI:** Para visualização e *storytelling* de dados.
- 🔗 **Excel:** Para *sanity checks* e validação de KPIs.

Obrigatório as seguintes componentes:

- Modelação/consulta
- Análise em Python
- Visualização em Power BI

4. Fontes de Dados

Os grupos deverão utilizar *datasets* reais ou realistas, obtidos a partir de repositórios públicos de dados. A escolha do *dataset* deve ser devidamente justificada em função do problema de negócio definido.

Sugerem-se, de seguida, algumas fontes.

Repositórios de Dados Públicos

- ✚ **Kaggle**
<https://www.kaggle.com/datasets>
(Grande variedade de datasets para Machine Learning e análise de negócio)
- ✚ **UCI Machine Learning Repository**
<https://archive.ics.uci.edu/>
(Datasets clássicos e académicos)
- ✚ **Google Dataset Search**
<https://datasetsearch.research.google.com/>
(Motor de pesquisa de datasets)
- ✚ **Data.gov (EUA)**
<https://www.data.gov/>
- ✚ **EU Open Data Portal**
<https://data.europa.eu/>
- ✚ **INE (Portugal)**
<https://www.ine.pt/>

Requisitos do Dataset

O *dataset* escolhido deve:

- ✚ Ter dimensão suficiente para análise (mínimo recomendado: 500 registos)
- ✚ Conter variáveis numéricas e categóricas
- ✚ Permitir a definição de um problema analítico relevante
- ✚ Ser adequado para pelo menos um modelo preditivo

Notas Importantes

- ✚ Não são permitidos *datasets* triviais ou excessivamente simplificados;
- ✚ Não são permitidos datasets com target demasiadamente óbvia sem discussão;
- ✚ Não poderão limitar-se a reproduzir um tutorial;
- ✚ Deverão justificar a escolha da variável alvo e das métricas;
- ✚ Deverão explicitar pelo menos um risco de enviesamento, qualidade de dados ou limitações do modelo.
- ✚ A qualidade do *dataset* será considerada na avaliação do projeto.

5. Modelo de Avaliação

✚ **Projeto Integrador (40%):** Avalia a estratégia completa, a coerência técnica e a qualidade das entregas incrementais efetuadas ao longo das sessões.

- ✓ 10% Problema e enquadramento
- ✓ 10% Arquitetura e pipeline
- ✓ 10% Modelação e ML
- ✓ 10% Qualidade técnica e coerência

✚ **Apresentação e Defesa (40%):** Defesa oral onde será avaliado o domínio técnico; a coerência entre problema, dados e solução; a clareza na comunicação; e a capacidade de argumentar as decisões tomadas perante a equipa docente.

✚ **Atividades Individuais (20%):** Participação ativa e contribuições nos laboratórios ao longo do trimestre.

6. O que têm que entregar

- ✚ Relatório técnico estruturado (docx/pdf)
- ✚ Dashboard (*Power BI*)
- ✚ Código (*Python / SQL*) comentado e reproduzível
- ✚ *Dataset* com fonte e breve descrição do processo de seleção e validação dos dados
- ✚ Apresentação final (pptx/pdf)

7. Datas Críticas

- **Entrega do Projeto:** 27 de abril.
- **Defesa do Projeto:** 29 de abril