

MESTRADO EM CIÊNCIA DE DADOS PARA EMPRESAS

- Analítica de Dados Empresariais -



Análise Preditiva de Churn no Setor das Telecomunicações:

Identificação de Clientes em Risco e Estratégias de Retenção

Projeto Integrador

2025/2026

Docente:

Luis Pereira

Ana Mendes

Discente:

Rui Rodrigues 130322017@estudantes.ips.pt

João Costa 201901343@estudantes.ips.pt

Sonia Bento 2025112328@estudantes.ips.pt

Índice

Enquadramento e Objetivo	1
Estratégia, Valor e Monetização	2
1. <i>Diagnóstico de Maturidade Analítica</i>	2
2. <i>Monetização dos Dados e Apoio à Decisão</i>	3
Arquitetura Técnica e Pipeline de Dados	5
1. <i>Arquitetura de Referência</i>	5
2. <i>Pipeline de Dados - ETL</i>	7
Modelação e Armazenamento	8
1. <i>Customer Management App (CMA)</i>	8
2. <i>Orchestrator</i>	8
3. <i>Modelos de Machine Learning</i>	8
4. <i>Decision Engine</i>	9
5. <i>Componente de Inteligência Artificial (LLM + RAG)</i>	9
6. <i>Fluxo entre as Aplicações</i>	9
Customer Loyalty Engine -Telco Chum (ADE)	10
Data Governance, Qualidade e Privacidade dos Dados	11
1. <i>Governance de Dados</i>	11
2. <i>Qualidade dos Dados</i>	12
3. <i>Privacidade e Proteção de Dados (RGPD)</i>	12
4. <i>Integração dos três pilares no projeto</i>	13
Domínios Analíticos e Aplicação Prática	14
1. <i>Domínio Descritivo e Diagnóstico (Compreensão do Problema)</i>	14
2. <i>Domínio Preditivo (Modelação e Quantificação do Risco)</i>	15
3. <i>Domínio Prescritivo (Apoio à Decisão e Ação)</i>	15
4. <i>Integração com Métricas e Valor de Negócio</i>	16
5. <i>Síntese Crítica</i>	16
Gestão de Projeto e Roadmap de Implementação	17
1. <i>Roadmap de Implementação, Recursos utilizados e KPI's</i>	17
2. <i>Gestão de Risco</i>	21
Conclusões e Recomendações Estratégicas	23
1. <i>Principais Conclusões</i>	23
2. <i>Insights Chave</i>	23
3. <i>Recomendações de Negócio</i>	24
4. <i>Limitações do Projeto</i>	24
Trabalho Futuro e Evolução da Solução Analítica	25
Referências	27

Estratégia *End-to-End* de Análise e Retenção de Clientes

Enquadramento e Objetivo

Num contexto empresarial cada vez mais competitivo, a retenção de clientes assume um papel central na sustentabilidade e crescimento das organizações, particularmente no setor das telecomunicações. Este setor caracteriza-se por uma elevada concorrência e baixos custos de mudança para o cliente, o que torna o fenómeno de abandono (*churn*) um desafio crítico. A perda de clientes não só reduz a receita recorrente como implica custos adicionais associados à aquisição de novos clientes, tornando essencial a adoção de estratégias proativas de retenção.

Neste contexto, a análise de dados e a aplicação de técnicas de *Machine Learning* têm vindo a assumir um papel fundamental no apoio à tomada de decisão, permitindo às organizações antecipar comportamentos e desenvolver ações direcionadas. A análise preditiva do *churn* possibilita identificar padrões associados ao abandono, segmentar clientes de acordo com o risco e implementar medidas preventivas mais eficazes.

O presente projeto tem como objetivo principal desenvolver uma abordagem analítica para prever o *churn* de clientes, contribuindo para a definição de estratégias de retenção mais eficientes. Para tal, foi utilizado o *Telco Customer Churn Dataset*, disponibilizado pela IBM [IBM Sample Data Sets] e partilhado no repositório de dados públicos *Kaggle*.

Este conjunto de dados contém informação de 7.043 clientes da empresa de telecomunicações Telco, incluindo variáveis demográficas (como género e composição do agregado familiar), características contratuais (tipo de contrato, método de pagamento e duração da relação com o cliente) e dados relativos à utilização de serviços (internet, segurança online, suporte técnico, entre outros). A variável-alvo é designada por *Churn* e indica se o cliente abandonou ou não o serviço no período recente.

Com base neste *dataset*, pretende-se analisar os fatores que influenciam o *churn*, identificar segmentos de maior risco e desenvolver modelos preditivos capazes de estimar a probabilidade de abandono. O objetivo final consiste em apoiar a tomada de decisão estratégica, permitindo à

organização atuar de forma antecipada e reduzir a taxa de *churn*, melhorando simultaneamente a experiência do cliente e a rentabilidade do negócio.

Estratégia, Valor e Monetização

1. Diagnóstico de Maturidade Analítica


A avaliação do nível de maturidade analítica da organização permite compreender em que medida os dados são utilizados para apoiar a tomada de decisão e gerar valor. De acordo com (Davenport T. H., 2006) as organizações evoluem ao longo de diferentes níveis de maturidade analítica, desde abordagens descritivas até modelos mais avançados orientados para a otimização e automação de decisões.


No contexto do presente projeto, a empresa Telco apresenta um nível de maturidade situado entre as fases descritiva e diagnóstica, evidenciando já alguma capacidade de análise para monitorizar indicadores e identificar padrões de comportamento dos clientes, mas ainda com limitações ao nível da antecipação e automatização de decisões.

Através do *dashboard* desenvolvido, é possível observar indicadores-chave como a taxa de *churn* 26,54%, o número total de clientes e a distribuição do abandono por tipo de contrato e serviço de internet. Estes elementos refletem uma utilização consistente de *analytics* descritivo, permitindo responder à questão “o que está a acontecer?”. Por exemplo, verifica-se que clientes com contratos *month-to-month* apresentam maior incidência de *churn*, bem como diferenças relevantes entre tecnologias de acesso à internet, como *fiber optic* e *DSL*.

Adicionalmente, a análise permite evoluir para um nível diagnóstico, ao identificar padrões e possíveis causas associadas ao abandono, respondendo à questão “porque está a acontecer?”. A segmentação por tipo de contrato e serviço evidência fatores de risco que podem estar associados à menor fidelização e maior probabilidade de *churn*.

16.06M	7.043K	1.869K	26.54%
Total Sales	Count of customerID	Churn Positive	Churn %





No entanto, tal como referido por (Davenport T. H., 2006) a criação de vantagem competitiva sustentável exige a evolução para níveis mais avançados, onde os dados suportam decisões preditivas e prescritivas. Neste sentido, a organização ainda não integra plenamente capacidades preditivas ou prescritivas nos seus processos. Não existe evidência de utilização de modelos que permitam antecipar o abandono de clientes nem de sistemas que recomendem automaticamente ações de retenção. Assim, as decisões tendem a ser reativas, baseadas em dados históricos, em vez de proativas.

Adicionalmente, conforme defendido por (Provost & Fawcett, 2013) a análise de dados deve estar orientada para a criação de valor, sendo fundamental a sua ligação direta a decisões de negócio. Assim, a evolução para uma abordagem preditiva permite transformar dados em conhecimento acionável, aumentando a capacidade da organização em atuar de forma proativa.

O presente projeto propõe a utilização de modelos de *Machine Learning* para previsão do *churn*, permitindo antecipar comportamentos e apoiar decisões mais informadas.

Deste modo, conclui-se que a organização apresenta uma base analítica sólida, com potencial de evolução para níveis mais avançados de maturidade, onde os dados desempenham um papel central na tomada de decisão e na criação de valor.

2. Monetização dos Dados e Apoio à Decisão

A utilização de dados no contexto da retenção de clientes apresenta um elevado potencial de monetização, tanto de forma direta como indireta, através da melhoria da eficiência operacional e do aumento da receita.


A monetização dos dados refere-se à capacidade de transformar informação em valor económico, seja através do aumento da receita, redução de custos ou melhoria da eficiência operacional. De acordo com (Provost & Fawcett, 2013) o verdadeiro valor da análise de dados

reside na sua aplicação prática na tomada de decisão, sendo essencial alinhar os modelos analíticos com objetivos de negócio concretos.

No contexto deste projeto, a análise de *churn* permite identificar segmentos de clientes com maior probabilidade de abandono, possibilitando a implementação de estratégias de retenção direcionadas. O *dashboard* desenvolvido constitui uma ferramenta fundamental de apoio à decisão, permitindo transformar dados em informação acionável. A identificação de segmentos com maior risco de *churn*, como clientes com contratos mensais, possibilita direcionar campanhas de retenção mais eficazes, reduzindo a probabilidade de abandono. Esta abordagem contribui diretamente para a redução da perda de receita, ao aumentar a retenção de clientes existentes.

Adicionalmente, conforme referido por (Davenport T. H., 2006) as organizações que utilizam dados de forma estratégica conseguem obter vantagens competitivas significativas, nomeadamente através da otimização de processos e melhoria da experiência do cliente. Neste sentido, o *dashboard* desenvolvido e os modelos preditivos propostos permitem apoiar decisões mais eficientes e fundamentadas.

A estratégia de retenção baseada na segmentação por níveis de risco (30%, 50% e 70%) constitui um exemplo claro de aplicação prática da análise de dados à decisão. Esta abordagem permite ajustar as ações ao perfil de cada cliente, otimizando recursos e aumentando a eficácia das intervenções. A segmentação por tipo de serviço permite ajustar estratégias comerciais, como a oferta de pacotes mais adequados ou a melhoria de serviços com maior taxa de *churn*. Estas ações podem resultar no aumento do valor do cliente ao longo do tempo (*Customer Lifetime Value*) e na otimização da proposta de valor da empresa.



Do ponto de vista da eficiência, a utilização de *analytics* permite reduzir custos associados a campanhas generalizadas, substituindo-as por ações direcionadas a clientes com maior probabilidade de abandono. Assim, os recursos são utilizados de forma mais eficiente, contribuindo para uma melhor relação custo-benefício.

Apesar destes benefícios, o verdadeiro potencial de monetização será alcançado com a evolução para *analytics* preditivo e prescritivo. A implementação de modelos capazes de prever o *churn* permitirá atuar de forma antecipada, enquanto sistemas prescritivos poderão recomendar automaticamente a melhor ação a aplicar a cada cliente.

Desta forma, o presente projeto demonstra como a análise de dados pode ser integrada no processo de decisão, contribuindo para a criação de valor económico e estratégico, e reforçando a importância de uma abordagem data-driven na gestão de clientes.



Arquitetura Técnica e Pipeline de Dados

1. Arquitetura de Referência

A definição de uma arquitetura analítica robusta constitui um elemento central para garantir a transformação eficiente de dados em informação útil para apoio à decisão. No âmbito do presente projeto, foi desenhada uma arquitetura analítica moderna, estruturada em diferentes camadas interdependentes, permitindo assegurar a integração, processamento e disponibilização de dados de forma consistente.

A arquitetura proposta segue uma abordagem *end-to-end*, organizada nas seguintes camadas: fontes de dados, integração e ingestão, armazenamento analítico, processamento e análise, e consumo. Esta estrutura permite responder ao problema comum de dados dispersos e sistemas isolados, assegurando uma visão integrada da informação.

Na camada de fontes de dados, consideram-se dados internos da organização, nomeadamente informação de clientes, contratos, serviços subscritos e histórico de faturação, provenientes de sistemas operacionais e de gestão.

A camada de integração e ingestão é responsável pela recolha e preparação dos dados, garantindo a sua qualidade e consistência antes de serem utilizados para análise. Esta camada desempenha um papel fundamental na normalização e consolidação da informação proveniente de diferentes fontes.

Relativamente ao armazenamento analítico, foi adotada uma solução baseada *SQL database*, adequada ao tipo de dados estruturados utilizados neste projeto. Esta escolha permite organizar os dados de forma otimizada para análise, garantindo elevado desempenho em consultas analíticas e suporte a histórico de dados, em linha com os princípios defendidos por (Ross, 2013). Na camada de processamento e análise, são aplicadas técnicas de análise descritiva, diagnóstica e preditiva, incluindo agregações, exploração de dados e desenvolvimento de modelos de *Machine Learning* para previsão de *churn*.

Por fim, a camada de consumo materializa-se através de *dashboards* interativos desenvolvidos em *Power BI*, permitindo aos decisores explorar os dados e obter *insights* relevantes para suporte à decisão. Conforme referido por (al., 2018) sistemas de *Business Intelligence* desempenham um papel fundamental na transformação de dados em informação acionável, suportando decisões estratégicas nas organizações.

A arquitetura foi desenhada e representada na plataforma *Lucidchart*, permitindo uma visualização clara das diferentes camadas e dos fluxos de dados entre elas. Esta abordagem contribui para uma melhor compreensão do *pipeline* analítico e facilita a comunicação entre equipas técnicas e de negócio.

2. Pipeline de Dados - ETL

No desenvolvimento do pipeline de dados, foi adotada uma abordagem *ELT* (*Extract, Load, Transform*), em detrimento do modelo tradicional *ETL*. Esta decisão baseia-se na necessidade de maior flexibilidade e escalabilidade no processamento dos dados.

De acordo com (al., 2018), os sistemas modernos de *Business Intelligence* e *Analytics* requerem pipelines de dados eficientes que suportem a integração, transformação e disponibilização de informação de forma contínua, permitindo às organizações responder rapidamente às necessidades de análise.

No modelo *ELT*, os dados são inicialmente extraídos das fontes de origem e carregados diretamente no sistema de armazenamento (*SQL database*), sendo posteriormente transformados. Esta abordagem permite preservar os dados na sua forma original, facilitando auditoria, reprocessamento e adaptação a novos requisitos analíticos.

A fase de extração (*Extract*) consiste na recolha dos dados relevantes, incluindo variáveis demográficas, contratuais e de utilização de serviços presentes no *dataset* Telco. De seguida, na fase de carregamento (*Load*), os dados são armazenados no *SQL database*, garantindo centralização e disponibilidade para análise.

Posteriormente, ocorre a fase de transformação (*Transform*), onde os dados são limpos, tratados e preparados para análise. Este processo inclui tarefas como tratamento de valores em falta, conversão de variáveis categóricas, criação de métricas e normalização dos dados.

A escolha do modelo *ELT* mostra-se vantajoso no contexto deste projeto. Em primeiro lugar, permite maior eficiência no processamento de grandes volumes de dados, aproveitando o poder computacional do sistema de armazenamento. Em segundo lugar, facilita a reutilização dos dados para diferentes análises, uma vez que as transformações são realizadas de forma flexível e iterativa. Por fim, esta abordagem está alinhada com arquiteturas analíticas modernas e com as melhores práticas atuais em engenharia de dados.

Adicionalmente, a centralização dos dados num *SQL database* está em linha com os princípios definidos por (Ross, 2013) que destacam a importância de estruturas organizadas e orientadas à análise para suportar processos de decisão.

Deste modo, o pipeline *ELT* implementado garante um fluxo de dados eficiente, desde a sua origem até à disponibilização para análise, suportando o desenvolvimento de modelos preditivos e a criação de insights relevantes para a organização.

Modelação e Armazenamento

De acordo com a (International, 2017), uma gestão eficaz de dados requer a integração destes domínios ao longo de todo o ciclo de vida da informação, garantindo consistência e alinhamento com os objetivos organizacionais.

1. *Customer Management App (CMA)*

A *Customer Management App* é responsável pela gestão operacional dos clientes. Inclui:

- *Frontend*, que permite aos utilizadores visualizar informação de clientes e interagir com o Sistema;
- *Backend*, que trata da lógica de negócio associada à gestão de dados.

Esta aplicação gere:

- Dados de clientes;
- Histórico de interações;
- Informação contractual.

Os dados são armazenados na *Database* (Telco *CMA*), uma base de dados relacional que assegura consistência e integridade da informação.

2. *Orchestrator*

O *Orchestrator* constitui o núcleo inteligente do sistema, sendo responsável pela avaliação do risco de *churn* e pela coordenação do processo de decisão.

Tal como a *CMA*, encontra-se dividido em:

- *Frontend* (para monitorização e controlo);
- *Backend*, onde reside a lógica principal.

O *Orchestrator* utiliza uma *Database* (Telco *Orchestrator*) para armazenar estados intermédios, resultados de modelos e dados necessários ao processo de decisão.

3. *Modelos de Machine Learning*

No interior do *Orchestrator* são executados dois modelos:

- Regressão Logística: actua como primeira camada de avaliação, identificando a probabilidade inicial de *churn*;

- *Random Forest*: aplicado em casos selecionados (por exemplo, clientes com maior risco), permitindo uma análise mais rigorosa.

Estes modelos utilizam dados provenientes das bases de dados para treinar e gerar previsões.

4. *Decision Engine*

O *Decision Engine*, integrado no *Orchestrator*, recebe os resultados dos modelos e classifica os clientes em níveis de risco:

- Risco Nulo;
- Risco Baixo;
- Risco Médio;
- Risco Alto.

Com base nesta classificação, determina automaticamente a ação mais adequada. Em caso do risco ser alto, é feita uma segunda análise para garantir que o cliente é de alto risco e evitar contactos desnecessários.

5. *Componente de Inteligência Artificial (LLM + RAG)*

O sistema inclui um módulo adicional baseado em *Large Language Models (LLM)*, suportado por uma *Knowledge Base* e técnicas de *Retrieval Augmented Generation (RAG)*.

Este componente permite enriquecer a análise, fornecendo suporte à interpretação dos dados e geração de *insights* relevantes.

Por motivos de governança, este modelo vai ser instânciado numa máquina local da qual nós temos total controle sobre os dados que são enviados para a mesma. Desta forma cumprimos com o RGPD, mantendo a confidencialidade dos dados dos clientes da empresa.

O software utilizado é o *Ollama*, um software *opensource* com licença do *MIT* que pode ser corrido localmente.

6. *Fluxo entre as Aplicações*

A *Customer Management App* fornece os dados operacionais dos clientes, que são utilizados pelo *Orchestrator* para:


- Treinar modelos;
- Realizar previsões;

- Suportar decisões.

Após a avaliação, o *Orchestrator* inicializa o *Decision Engine* e toma as devidas ações.

A separação do sistema em duas aplicações, *CMA* e *Orchestrator*, permite distinguir claramente a gestão operacional da lógica de decisão, resultando numa arquitectura modular, escalável e adequada à implementação de um sistema de previsão e mitigação de *churn* em contexto real.

Customer Loyalty Engine -Telco Churn (ADE)



Data Governance, Qualidade e Privacidade dos Dados

A gestão de dados no contexto analítico assenta em três pilares fundamentais que funcionam de forma interdependente: *governance*, qualidade e privacidade. Assim, a ausência de qualquer um destes elementos nos conteúdos teóricos compromete a fiabilidade dos resultados e, consequentemente, a qualidade das decisões organizacionais. Neste sentido, o presente projeto integra estes três pilares de forma articulada, assegurando que os dados utilizados são controlados, fiáveis e utilizados de forma ética.

De acordo com a (International, 2017) a gestão de dados deve ser estruturada através de um conjunto de práticas, processos e políticas que garantam a qualidade, segurança e disponibilidade da informação ao longo do seu ciclo de vida, reforçando a importância de uma abordagem integrada como a adotada neste projeto.

1. *Governance de Dados*

A *data governance* define as regras, responsabilidades e processos associados à gestão dos dados dentro de uma organização. No contexto deste projeto, a *governance* está alinhada com a arquitetura analítica adotada, baseada num modelo de *SQL database*, o que permite uma abordagem centralizada e estruturada da informação.

Esta centralização garante maior controlo sobre os dados, facilitando a sua organização, padronização e consistência ao longo de todo o *pipeline* analítico. Desde a ingestão de dados através do processo *ELT* até à sua disponibilização em *dashboards*, existe uma lógica clara de fluxo e transformação da informação.

Embora o *dataset* utilizado seja externo, proveniente da *IBM*, foi adotada uma abordagem de responsabilidade analítica, assegurando que os dados são utilizados de forma adequada ao contexto do problema de negócio. A definição implícita da entidade cliente e utilização de apenas variáveis relevantes, contribui para uma estrutura coerente e evita ambiguidades na análise.

De acordo com (Khatri, 2010), a *data governance* deve estabelecer mecanismos claros de decisão e controlo sobre os dados, garantindo alinhamento entre objetivos de negócio e gestão da informação, o que se reflete na estrutura adotada neste projeto.

Assim, responde-se à questão-chave da *governance* “Quem controla e define as regras dos dados?”, sendo neste caso o controlo assegurado através da arquitetura definida e das boas práticas aplicadas ao longo do projeto.

2. *Qualidade dos Dados*

A qualidade dos dados é um fator determinante para garantir a confiança nos resultados analíticos. Dados incompletos, inconsistentes ou desatualizados podem comprometer significativamente a validade dos modelos desenvolvidos e das conclusões obtidas.

No presente projeto, foram aplicadas práticas de garantia de qualidade ao longo da fase de transformação do pipeline *ELT*. Estas incluem o tratamento de valores em falta, a normalização de variáveis, a validação de tipos de dados e a correta codificação de variáveis categóricas.

A *SQL database* é uma opção melhor no presente projeto porque alinha com o tipo de uso operacional e analítica simples, demonstrando uma menor latência.

Adicionalmente, a compreensão das variáveis do *dataset* permitiu assegurar que cada atributo é utilizado de forma correta e consistente no processo analítico, nomeadamente na construção de modelos preditivos de *churn*.

Segundo (Batini, 2016), a qualidade dos dados deve ser avaliada com base em dimensões como precisão, completude e consistência, sendo estes princípios refletidos nas práticas adotadas neste projeto.

Deste modo, responde-se à questão-chave da qualidade “Posso confiar nos dados?”, sendo garantido que os dados utilizados são precisos, completos e adequados ao objetivo do estudo.

3. *Privacidade e Proteção de Dados (RGPD)*

A privacidade dos dados constitui um requisito essencial no desenvolvimento de projetos analíticos, especialmente quando estão em causa informações relacionadas com clientes. Neste contexto, o projeto foi desenvolvido em conformidade com os princípios do Regulamento Geral sobre a Proteção de Dados (RGPD), garantindo um tratamento ético e legal da informação.

O *dataset* utilizado encontra-se anonimizado, não contendo dados pessoais identificáveis, como nomes, moradas, números de telefone ou endereços de email. Esta característica assegura o cumprimento do princípio da minimização de dados, uma vez que apenas são utilizados os atributos necessários para análise.

Adicionalmente, sendo um *dataset* disponibilizado pela *IBM* e publicado num repositório de dados públicos, assume-se que já cumpre requisitos de conformidade legal e boas práticas de proteção de dados.

De acordo com (Union., 2016), o RGPD estabelece princípios fundamentais como a transparência, limitação de finalidade e segurança no tratamento de dados pessoais, os quais são respeitados neste projeto.

Adicionalmente, conforme referido por (Solove, 2008), a proteção da privacidade deve ser entendida como um elemento central na gestão da informação, garantindo o equilíbrio entre utilização de dados e direitos individuais.

Do ponto de vista da segurança, práticas adequadas de controlo e proteção da informação são essenciais para mitigar riscos, conforme destacado por (Behl, 2017), reforçando a importância de ambientes controlados no tratamento de dados.

O projeto também respeita os princípios de transparência utilizando os dados apenas para fins analíticos claros, justificando a sua finalidade de uso exclusivo para a análise de *churn* e garantido a segurança sendo o seu tratamento efetuado em ambiente controlado.

Assim, responde-se à questão-chave da privacidade “Posso usar os dados legalmente?”, sendo assegurado que a utilização dos dados cumpre normas éticas e legais.

4. Integração dos três pilares no projeto

Os três pilares *governance*, qualidade e privacidade não atuam de forma isolada, mas sim como um sistema integrado que sustenta decisões organizacionais confiáveis. No contexto deste projeto a *governance* assegura estrutura e controlo dos dados, a qualidade garante fiabilidade e precisão da informação e a privacidade assegura conformidade legal e ética.

De acordo com a (International, 2017), uma gestão eficaz de dados requer a integração destes domínios ao longo de todo o ciclo de vida da informação, garantindo consistência e alinhamento com os objetivos organizacionais.

Esta integração é fundamental para que os resultados obtidos, nomeadamente os modelos preditivos de *churn* e os *dashboards* desenvolvidos, possam ser utilizados como suporte efetivo à tomada de decisão.

Assim, confirma-se que os dados só geram valor quando são controlados, fiáveis e seguros, reforçando a importância de uma abordagem estruturada de data *governance* no desenvolvimento de soluções analíticas.

Domínios Analíticos e Aplicação Prática

No presente projeto, orientado à análise e mitigação do *churn* de clientes, foram identificados três domínios analíticos fundamentais, a análise descritiva e diagnóstica, a modelação preditiva e a decisão prescritiva, os quais sustentam uma cadeia de valor contínua e integrada. Estes domínios não funcionam de forma isolada, mas sim como uma cadeia de valor integrada, alinhada com a abordagem *CRISP-DM* e sustentada por práticas de *DataOps* e *MLOps* previamente definidas, enquanto estrutura orientadora do processo analítico, desde a compreensão do problema até à operacionalização das soluções (Plotnikova, 2022).

1. Domínio Descritivo e Diagnóstico (Compreensão do Problema)

O primeiro domínio centra-se na exploração e compreensão dos dados, permitindo identificar padrões, tendências e fatores associados ao *churn*. Através de técnicas de análise exploratória (*EDA*), correlação e análise de variáveis relevantes (como *tenure*, *MonthlyCharges* e tipo de contrato), foi possível caracterizar o comportamento dos clientes e identificar segmentos com maior propensão à saída.

Este domínio assume um papel fundamental, na medida em que garante a coerência entre o problema de negócio e a modelação subsequente. De acordo com (Plotnikova, 2022), a qualidade das fases iniciais do processo *CRISP-DM* condiciona diretamente a eficácia dos modelos desenvolvidos, uma vez que decisões incorretas nesta fase tendem a propagar-se ao longo de todo o pipeline analítico.

No contexto do projeto, esta etapa permitiu não apenas compreender o fenómeno do *churn*, mas também estabelecer as bases para uma segmentação futura orientada à decisão.

2. Domínio Preditivo (*Modelação e Quantificação do Risco*)

O segundo domínio corresponde à construção e avaliação de modelos de *Machine Learning*, nomeadamente Regressão Logística e *Random Forest*, com o objetivo de estimar a probabilidade de *churn* para cada cliente.

O *output* destes modelos, um *score* de *churn* contínuo entre 0 e 1, constitui o principal ativo analítico do projeto, funcionando como um indicador quantitativo de risco. A avaliação dos modelos, baseada em métricas como *accuracy*, *recall* e *F1-score*, evidenciou uma capacidade robusta de identificação de clientes em risco, ainda que com *trade-offs* típicos entre precisão e sensibilidade.

Importa salientar que, apesar da relevância técnica destas métricas, o verdadeiro valor do domínio preditivo reside na sua capacidade de ser interpretado e integrado em processos de decisão. Como tal, este domínio funciona como ponte entre a análise e a ação, sendo insuficiente quando considerado de forma isolada.

3. Domínio Prescritivo (*Apoio à Decisão e Ação*)

O terceiro domínio representa a evolução para um nível mais avançado de maturidade analítica, onde os *outputs* dos modelos são convertidos em decisões acionáveis. Neste projeto, esta transição é operacionalizada através da definição de *thresholds* (30%, 50% e 70%) que segmentam os clientes em diferentes níveis de risco, permitindo adaptar estratégias de retenção específicas.

Esta lógica é implementada através de um *decision engine* que integra modelos preditivos com um sistema baseado em modelos de linguagem de grande escala, suportando a recomendação automática de ações. Neste contexto, a adoção de práticas associadas a *LLMOps* torna-se crítica, na medida em que permite gerir, monitorizar e evoluir estes sistemas de forma contínua (Raj, 2024). Adicionalmente, a transição de abordagens tradicionais de *MLOps* para *LLMOps* introduz novos desafios, nomeadamente ao nível da governança dos *outputs*, controlo de custos e fiabilidade das respostas geradas. Segundo (Zhang, 2025), a operacionalização de modelos generativos exige mecanismos adicionais de controlo e validação, dado o carácter probabilístico e não determinístico destes sistemas.

No âmbito do projeto, esta integração permite não apenas automatizar o contacto com clientes de elevado risco, mas também personalizar a comunicação com base no seu contexto, contribuindo para uma abordagem mais eficaz e orientada ao cliente.

4. Integração com Métricas e Valor de Negócio

A articulação entre os domínios descritivo, preditivo e prescritivo permite estabelecer uma cadeia de valor analítica completa, onde cada componente reforça os restantes. A análise descritiva garante a compreensão do problema, a modelação preditiva quantifica o risco e o domínio prescritivo transforma esse conhecimento em ação.

Neste contexto, o projeto demonstra que o valor não reside exclusivamente na capacidade de prever o *churn*, mas sim na capacidade de agir de forma eficaz sobre essa previsão. A integração com práticas de *DataOps*, *MLOps* e *LLMOps* assegura que este processo é contínuo, escalável e alinhado com os objetivos organizacionais.

5. Síntese Crítica

A lacuna entre análise e ação continua a ser um dos principais desafios nas organizações orientadas a dados. Neste sentido, a principal contribuição deste projeto reside na sua abordagem integrada, que combina rigor metodológico (*CRISP-DM*), robustez técnica (modelos preditivos) e operacionalização da decisão (*LLMOps*). Esta abordagem permite posicionar o sistema num nível avançado de maturidade analítica, aproximando-o de uma lógica prescritiva e orientada à criação de valor.

Contudo, esta evolução exige igualmente um reforço dos mecanismos de governança, controlo e validação, de forma a garantir que a automação da decisão não compromete a qualidade, a ética e a fiabilidade dos resultados.

Em síntese, os domínios analíticos estruturados neste projeto evidenciam que a transformação de dados em valor depende da integração entre análise, modelação e decisão. A incorporação de tecnologias emergentes, como modelos de linguagem, reforça esta capacidade, permitindo automatizar e escalar processos de decisão de forma inovadora.

Gestão de Projeto e Roadmap de Implementação

1. Roadmap de Implementação, Recursos utilizados e KPI's

O desenvolvimento do presente projeto seguiu uma abordagem estruturada, organizada em várias fases sequenciais, desde a definição conceptual até à implementação de um sistema de apoio à decisão baseado em inteligência artificial.

Fase 1 – Definição do Processo Analítico (Customer Loyalty Engine)

Numa fase inicial, foi desenhado o fluxo global do Sistema *Customer Loyalty Engine* (explicado no modulo acima Modelação e Armazenamento), com o objetivo de estruturar o processo de retenção de clientes de forma integrada. Este fluxo define as etapas desde a recolha de dados até à ativação de ações de retenção, permitindo uma visão *end-to-end* do processo analítico.

Este modelo conceptual estabelece a base para a transformação de dados em decisões, integrando componentes de análise preditiva e mecanismos de atuação sobre os clientes.

Fase 2 – Preparação e Modelação dos Dados

Seguidamente, procedeu-se à preparação dos dados, incluindo limpeza, tratamento de valores em falta, normalização de variáveis numéricas, codificação de variáveis categóricas previamente em ficheiro de excel.

Esta etapa é essencial para garantir a qualidade dos dados e a sua adequação aos modelos de *Machine Learning*.

Fase 3 – Desenvolvimento dos Modelos Preditivos


Foram desenvolvidos dois modelos principais para previsão do *churn*:

Regressão Logística: modelo base interpretável;

Random Forest: modelo mais robusto e com maior capacidade de captura de padrões complexos.

A regressão logística permitiu compreender a relação entre variáveis e *churn*, enquanto o *Random Forest* foi utilizado para melhorar a performance preditiva e analisar a importância das variáveis.

A análise da importância da *feature* evidenciou que variáveis como *tenure*, *monthly charges* e tipo de contrato têm um impacto significativo na probabilidade de *churn*.



Fase 4 – Avaliação dos Modelos

A performance dos modelos foi avaliada com base em métricas como:

Accuracy $\approx 75\% - 78\%$

Recall (churn) $\approx 75\% - 80\%$


F1-score (churn) $\approx 63\% - 64\%$

ROC AUC ≈ 0.84

A matriz de confusão demonstrou uma boa capacidade do modelo em identificar clientes com *churn*, sendo este aspeto crítico para o objetivo do projeto.

	precision	recall	f1-score	support
0	0.91	0.73	0.81	1294
1	0.52	0.80	0.63	467
accuracy			0.75	1761
macro avg	0.71	0.76	0.72	1761
weighted avg	0.81	0.75	0.76	1761
ROC AUC: 0.8461206226067272				

Confusion Matrix:				
[[1232 320]				
[142 419]]				
Classification Report:				
	precision	recall	f1-score	support
0	0.90	0.79	0.84	1552
1	0.57	0.75	0.64	561
accuracy			0.78	2113
macro avg	0.73	0.77	0.74	2113
weighted avg	0.81	0.78	0.79	2113



Fase 5 – Cálculo do Risco e Segmentação de Clientes

Com base nas probabilidades geradas pelos modelos, foi calculado o risco de *churn* para cada cliente, permitindo a sua segmentação em diferentes níveis:

≥ 70% : Alto risco (intervenção urgente);

50% – 70% : Risco médio (campanhas de retenção);

30% – 50% : Risco reduzido (monitorização);

< 30% : Cliente estável.



Esta segmentação constitui a base para a definição de estratégias de retenção diferenciadas.

```

Maior risco: 1
customerID  Churn
7590-VHVEG  0
5575-GNVDE  0
3668-QPYBK  1
7795-CFOCW  0
9237-HQITU  1
    
```

```

Maior risco: 0.9386570256743881
customerID  Churn
7590-VHVEG  0.791213
5575-GNVDE  0.120119
3668-QPYBK  0.538228
7795-CFOCW  0.074838
9237-HQITU  0.854206
    
```



Fase 6 – Decision Engine e Integração de LLM







Após o desenvolvimento dos modelos preditivos, foi concebido um *Decision Engine*, responsável por transformar previsões em ações concretas.

Este sistema integra um *Large Language Model* (LLM), com o objetivo de apoiar a tomada de decisão e automatizar a comunicação com os clientes. O modelo é continuamente alimentado com dados atualizados dos clientes, permitindo gerar respostas mais relevantes e personalizadas.

No caso de clientes de alto risco, o sistema pode sugerir ações de retenção, apoiar operadores em contactos diretos ou automatizar comunicações personalizadas.

Esta abordagem representa a evolução do projeto para um nível prescritivo, onde os dados não apenas informam, mas suportam e ativam decisões.

```
Recomendacao
Sem ação (cliente estável)      2983
Intervenção urgente (oferta forte / contacto direto)  1766
Monitorização + comunicação leve (email / push)      1173
Campanha de retenção (desconto / benefício)          1121
Name: count, dtype: int64
```



O desenvolvimento do projeto foi realizado com recurso à plataforma *Google Colab*, que permitiu execução de código em ambiente *cloud*, a integração de bibliotecas de *Machine Learning*,

a visualização de resultados e gráficos e o desenvolvimento iterativo do modelo. Adicionalmente, foram utilizadas ferramentas como *Python* (análise e modelação) e *Power BI* (visualização).

Para avaliar o sucesso da solução proposta, foram definidos os seguintes indicadores-chave de desempenho:

KPI's Técnicos

- Accuracy do modelo ($> 75\%$);
- Recall para *churn* ($\geq 75\%$);
- ROC AUC (> 0.80).

KPI's de Negócio

- Redução da taxa de *churn*;
- Aumento da retenção de clientes;
- Eficiência das campanhas de retenção;
- Taxa de conversão de ações (retenção vs abandono).

KPI's Operacionais

- Tempo de resposta na identificação de clientes em risco;
- Automação do processo de decisão;
- Redução de custos em campanhas generalizadas.

A estruturação do projeto em fases permite garantir uma abordagem integrada, desde a análise de dados até à implementação de um sistema inteligente de apoio à decisão, alinhando tecnologia, negócio e criação de valor.

2. *Gestão de Risco*

A implementação de soluções analíticas, especialmente aquelas que envolvem *Machine Learning* e automação da tomada de decisão, implica um conjunto de riscos que devem ser cuidadosamente identificados e geridos. No contexto do presente projeto, os principais riscos podem ser agrupados em três dimensões: técnica, organizacional e ética, sendo fundamental a definição de estratégias de mitigação adequadas para garantir a robustez e sustentabilidade da solução proposta.

Do ponto de vista técnico, um dos principais riscos está associado à qualidade e representatividade dos dados utilizados. Embora o *dataset* analisado seja amplamente utilizado em contextos académicos e se encontre previamente manipulado/ limpo, a sua natureza simulada pode

não refletir integralmente a complexidade de um ambiente real. Este fator pode comprometer a capacidade de generalização dos modelos desenvolvidos. Adicionalmente, existe o risco de *overfitting*, bem como limitações associadas à performance do modelo, nomeadamente na identificação correta de clientes em risco de *churn*. Como estratégia de mitigação, foram aplicadas técnicas de validação de modelos, análise de métricas de desempenho e utilização de diferentes algoritmos (regressão logística e *Random Forest*), permitindo uma avaliação comparativa e mais robusta dos resultados.

Ao nível organizacional, destacam-se riscos relacionados com a integração da solução nos processos de negócio e a adoção por parte dos utilizadores. A resistência à mudança, a falta de literacia analítica e a ausência de integração com sistemas existentes (como *CRM*) podem limitar o impacto da solução. Para mitigar estes riscos, propõe-se uma abordagem gradual de implementação, acompanhada de formação dos utilizadores e alinhamento com os objetivos estratégicos da organização. A utilização de *dashboards* intuitivos e de um *decision engine* contribui igualmente para facilitar a adoção e interpretação dos resultados.

Relativamente aos riscos éticos e legais, a utilização de dados de clientes levanta preocupações associadas à privacidade, transparência e potencial enviesamento dos modelos. Mesmo tratando-se de dados anonimizados, a aplicação de modelos preditivos pode gerar decisões que impactam diretamente os clientes, sendo essencial garantir a sua utilização responsável. Existe também o risco de discriminação indireta, caso determinadas variáveis influenciem desproporcionalmente as previsões. Como forma de mitigação, o projeto respeita os princípios do RGPD, assegura a anonimização dos dados e promove a transparência na utilização dos modelos. Adicionalmente, a utilização de modelos interpretáveis, como a regressão logística, permite compreender melhor os fatores que influenciam o *churn*.

Por fim, a integração de um *Large Language Model (LLM)* no processo de decisão introduz novos desafios, nomeadamente ao nível da fiabilidade das respostas e da dependência de dados atualizados. Para mitigar este risco, propõe-se que o modelo seja continuamente alimentado com dados relevantes da organização e utilizado como ferramenta de apoio à decisão, e não como substituto do julgamento humano.

Em suma, a gestão de risco assume um papel central no desenvolvimento deste projeto, sendo essencial não apenas identificar potenciais limitações, mas também implementar estratégias

que garantam a sua mitigação. Esta abordagem crítica permite reforçar a credibilidade da solução proposta e assegurar a sua aplicabilidade em contexto real.

A identificação e mitigação de riscos não constitui apenas um requisito técnico, mas um elemento essencial para garantir a confiança, sustentabilidade e impacto real das soluções analíticas nas organizações.

Conclusões e Recomendações Estratégicas

1. Principais Conclusões

O presente projeto permitiu analisar o fenómeno de *churn* no setor das telecomunicações, demonstrando o potencial da análise de dados como ferramenta de apoio à decisão. Através da exploração do *Telco Customer Churn Dataset*, disponibilizado pela *IBM*, foi possível identificar padrões relevantes no comportamento dos clientes e compreender os principais fatores associados ao abandono.

Os resultados evidenciam que a taxa de *churn* observada (26,54%) representa um risco significativo para a organização, reforçando a necessidade de adoção de estratégias de retenção mais eficazes. A análise revelou que fatores como o tipo de contrato, o serviço de internet e o tempo de permanência (*tenure*) têm impacto direto na probabilidade de *churn*.

Adicionalmente, verificou-se que clientes com contratos mensais (month-to-month) apresentam maior propensão ao abandono, enquanto contratos de maior duração contribuem para uma maior fidelização. Estes resultados confirmam a importância de compreender o ciclo de vida do cliente e adaptar as estratégias comerciais em conformidade.

2. Insights Chave

A análise realizada permitiu extrair um conjunto de *insights* relevantes para o negócio:

- a) Clientes com contratos de curta duração apresentam maior risco de *churn*;
- b) Serviços de maior valor (como *fiber optic*) estão associados a níveis mais elevados de abandono, possivelmente devido a expectativas mais elevadas;
- c) Clientes com menor tempo de permanência são mais propensos ao *churn*, evidenciando um período crítico inicial;

- d) A ausência de serviços adicionais (como suporte técnico ou segurança online) pode estar associada a menor fidelização.

Estas conclusões permitem identificar segmentos prioritários para intervenção, contribuindo para uma abordagem mais direcionada e eficiente.

3. *Recomendações de Negócio*

Com base nos resultados obtidos, são propostas as seguintes recomendações estratégicas:

- a) Implementar campanhas de retenção direcionadas para clientes com contratos mensais, oferecendo incentivos à migração para contratos de maior duração;
- b) Desenvolver estratégias de *onboarding* para novos clientes, reduzindo o risco de churn nos primeiros meses;
- c) Promover serviços adicionais, como suporte técnico e segurança, aumentando o valor percebido e a fidelização;
- d) Utilizar modelos preditivos de *churn*, permitindo identificar clientes em risco e atuar de forma proativa;
- e) Personalizar ofertas comerciais, com base no perfil e comportamento do cliente

Estas ações contribuem para a redução da taxa de *churn*, aumento da receita e melhoria da experiência do cliente.

4. *Limitações do Projeto*

Apesar dos resultados obtidos, o projeto apresenta algumas limitações que devem ser consideradas:

- a) *Dataset* utilizado não possui dimensão temporal, limitando a análise da evolução do *churn* ao longo do tempo;
- b) Os dados são simulados e não refletem totalmente a complexidade de um ambiente real;
- c) A ausência de variáveis comportamentais mais detalhadas pode limitar a capacidade explicativa dos modelos;
- d) A análise baseia-se num contexto específico, podendo não ser totalmente generalizável

Estas limitações sugerem a necessidade de cautela na interpretação dos resultados.

Trabalho Futuro e Evolução da Solução Analítica

Como evolução do presente projeto, propõe-se a transição de uma abordagem preditiva para uma solução prescritiva e automatizada, capaz de não só prever o *churn*, mas também atuar em tempo real com base no nível de risco identificado.

Neste contexto, foi definida uma estratégia de retenção baseada num *decision flow*, onde os clientes são segmentados de acordo com a probabilidade de *churn*, permitindo associar ações específicas a cada nível de risco:

Risco Nulo: não são necessárias ações;

Risco baixo: campanhas de retenção ligeiras (ex.: descontos ou benefícios);

Risco médio: monitorização ativa e comunicação personalizada (email ou *push*);

Risco Elevado: intervenção imediata com contacto direto e ofertas personalizadas pelo *LLM*.

Esta abordagem permite otimizar a alocação de recursos, garantindo que as ações mais intensivas que são direcionadas apenas para os clientes com maior probabilidade de abandono.

Uma das principais evoluções propostas consiste na integração de um *Large Language Model (LLM)* no processo de retenção, permitindo automatizar e personalizar a comunicação com os clientes de forma mais eficaz. Este modelo será continuamente alimentado com dados atualizados dos clientes que apresentam Risco Elevado, incluindo histórico de interações, serviços contratados e comportamento, permitindo gerar respostas mais ajustadas, relevantes e contextuais.

No âmbito da estratégia de retenção, o cálculo do risco de *churn* foi realizado através da aplicação de um modelo preditivo que estima a probabilidade de cada cliente abandonar o serviço. O modelo gera um score contínuo entre 0 e 1, onde valores mais próximos de 1 indicam maior probabilidade de *churn*. Com base nestes resultados, foi definida uma segmentação dos clientes em diferentes níveis de risco, permitindo uma abordagem mais direcionada e eficiente. Em particular, foram estabelecidos três limiares principais: clientes com probabilidade igual ou superior a 70% são considerados de alto risco, exigindo intervenção imediata, clientes com probabilidade entre 50% e 70% são classificados como risco médio, sendo alvo de campanhas de retenção, e clientes com probabilidade entre 30% e 50% são considerados de risco reduzido, sendo acompanhados através de ações de monitorização e comunicação leve. Esta segmentação permite

alinhar a estratégia de retenção com o nível de risco de cada cliente, otimizando recursos e aumentando a eficácia das ações implementadas.

Esta integração permite automatizar o processo de contacto com os clientes com base na sua segmentação, aumentando a eficiência operacional e, consequentemente, melhorando a experiência do cliente através de uma comunicação mais relevante, personalizada e contextualizada.

Adicionalmente, a implementação desta solução num ambiente real implicaria a integração com sistemas operacionais, como *CRM* e plataformas de marketing *automation*, permitindo a atualização contínua dos scores de *churn*, a execução automática de campanhas e a monitorização do impacto das ações de retenção.

Por fim, esta evolução posiciona o projeto num nível avançado de maturidade analítica, aproximando-o de uma arquitetura prescritiva e orientada à decisão, onde os dados não apenas informam, mas também impulsionam ações concretas no negócio.

Referências

- al., S. e. (2018). *Cap. 1: Introdução ao Business Intelligence e Analytics*.
- Batini, C. &. (2016). *Data and information quality: Dimensions, principles and techniques*. Springer.
- Behl, A. &. (2017). *Cybersecurity and cyberwar: What everyone needs to know*. Oxford University Press.
- Dados, R. G. (n.d.). *RGPD*.
- Davenport, T. H. (2006). pp. 98-107.
- International, D. (2017). *The DAMA guide to the data management body of knowledge (DAMA-DMBOK2) (2nd ed.)*. Technics Publications.
- Khatri, V. &. (2010). *Designing data governance*. *Communications of the ACM*, 53(1), 148–152. <https://doi.org/10.1145/1629175.1629210>.
- Provost, F., & Fawcett, T. (2013). *Data science for business*. Sebastopol: O'Reilly.
- Ross, R. K. (2013). *Cap. 1: Fundamentos do Data Warehouse e modelação dimensional*.
- Solove, D. J. (2008). *Understanding privacy*. Harvard University Press.
- Union., E. P. (2016). *Regulation (EU) 2016/679 of the European Parliament and of the Council of 27 April 2016 on the protection of natural persons with regard to the processing of personal data and on the free movement of such data (General Data Protection Regulation)*. Official Journal of the European Union, L119, 1–88.